


Exercice ETL on premise et simulation approche medallion


Cet exercice permet d'appréhender de manière simplifiée Apache Hop et l'approche medallion. Deux sources de données, l'ERP et le CRM, sont simulées avec des fichiers CSV. L'objectif est de créer les objets en base de données nécessaires ainsi que les pipelines pour import et transformer les données. Les extractions seront toujours intégrales (full).



Base de données

Créer trois schémas bronze, silver et gold dans une base de données PostgreSQL pour simuler l'approche medallion.

Bronze layer



Créer les six tables stockant les données des fichiers CSV.


Dans la table `crm_sales_details`, stocker les champs date (`_dt`) sous forme d'entier.

Créer des pipelines avec Apache HOP (ou autre) pour charger les fichiers CSVs dans les tables du schéma bronze.

Analyse des données sources

Les données du CRM seront enrichies avec les données provenant de l'ERP. Les champs permettant les jointures entre les tables nécessitent des transformations.

Data Integration (how to tables are related)



Dans l'ERP, la catégorie produit a un id stocké sur 5 caractères contenant un underscore : AC_BR

Dans le CRM, le produit a une clé contenant la catégorie avec un tiret et la clé produit utilisé dans la vente : CO-RF-FR-R92B-58.


Dans la couche silver, il faudra ajouter une colonne cat_id et remplacer prd_key. Par exemple, la valeur de prd_key CO-RF-FR-R92B-58 sera transformée comme suit :

Valeur d'origine : CO-RF-FR-R92B-58

cat_id : CO_RF

prd_key : FR-R92B-58

Silver Layer



Créer des pipelines avec Apache HOP (ou autre) pour charger les données des tables du schéma bronze dans le schéma silver. Les tables conservent le même nom.

Ajouter un champ dwh_create_date dans toutes les tables de la couche silver contenant par défaut la date d'insertion.

Les transformations peuvent être effectuées avec SQL ou dans l'ETL.

Table crm_customer_info

- Gérer les doublons, prendre la version la plus récente du client
- Effectuer un trim du prénom et du nom

cst_marital_status

Dans la couche Silver, remplacer les données par Single, Married ou n/a

cst_gndr

Dans la couche Silver, remplacer les données par Female, Male ou n/a

Table crm_prd_info

Créer une colonne cat_id contenant (substring(prd_key, 1, 5), remplacement – en _ pour effectuer la jointure avec la table erp_px_cat_g1v2.

Remplacer les valeur de la colonne prd_key par la prd_key originale
SUBSTRING(prd_key, 7, LEN(prd_key))

prd_cost

Remplace les valeurs nulls par 0

prd_line

Remplacer les codes avec les valeurs suivantes :

M – Mountain
R – Roads
S – Other Sales
T – Touring
n/a

Table crm_sales_details

Champs date

Pour les champs date, si la valeur est égale à zéro ou sa longueur différente de 8, remplacer par null. Convertir les valeurs valides en date

- sls_order_dt
- sls_ship_dt
- sls_due_dt

sls_sales

recalculer la valeur si null ou plus petit ou égal à 0 avec les champs sls_quantity et sls_price.

sls_price

recalculer la valeur si null ou plus petit ou égal à 0 avec les champs sls_sales et sls_quantity

Tables erp_cust_az12

bdate

Les dates de naissances plus grandes qu'aujourd'hui doivent être nulle

gen

Le genre doit être codifié :

'F', 'FEMALE' => Female

'M', 'MALE' => Male

Table erp_loc_a101

cid

Enlever les tirets du champ.

Cntry

Trimer les valeurs

Remplacer DE par Germany

Remplacer US ou USA par United Stages.

Les pays vides doivent être n/a

erp_px_cat_g1v2

Extract, Load, pas de transformation

Gold Layer

Créer les tables de dimensions et de fait. Créer les pipelines pour alimenter les tables.
Effectuer les jointures nécessaires pour remplir les tables avec les données de l'ERP et du CRM.